

Construction du jeu de données

Collecte des données

Les données utilisées dans ce projet proviennent de deux sources publiques disponibles sur Kaggle :

- le dataset [Elite Prospects Hockey Stats Player Data](#) ;
- le dataset [NHL Draft Hockey Player Data 1963–2022](#).

Le premier lien regroupe deux datasets complémentaires :

- un dataset contenant les informations générales des joueurs (caractéristiques physiques, position, nationalité), ainsi que certaines informations de draft ;
- un second dataset contenant les statistiques des joueurs par saison, décrivant leurs performances détaillées (matches joués, buts, passes, points, etc.).

Le dataset principal ne contenait pas systématiquement la variable cible du problème, à savoir le rang de draft (`DRAFT_OVERALL`), certaines valeurs étant manquantes pour un nombre important de joueurs.

Afin de compléter ces informations, le dataset issu du second lien a été utilisé. Une table spécifique a permis de récupérer les données de draft des joueurs, notamment leur rang de sélection.

Ainsi, le dataset final repose sur la combinaison de trois sources :

- les informations descriptives des joueurs ;
- leurs statistiques saisonnières ;
- les données de draft.

Ces différentes sources ont été téléchargées au format CSV puis importées dans un environnement Python afin d'être traitées et intégrées dans le processus de construction du dataset final.

Enrichissement et fusion des données

Les joueurs du dataset principal ont été séparés en deux groupes :

- les joueurs disposant déjà d'un rang de draft ;
- les joueurs pour lesquels cette information était manquante.

Afin de compléter ces valeurs, une jointure a été réalisée avec le dataset NHL.

Une variable `birth_year` a été reconstruite à partir de l'année de draft et de l'âge du joueur :

$$\text{birth_year} = \text{year} - \text{age}$$

L'année de naissance a également été extraite du dataset principal à partir de la date de naissance des joueurs.

Une variable `player` a été construite en concaténant le prénom et le nom afin de faciliter la correspondance.

La jointure a été effectuée en utilisant le nom du joueur et l'année de naissance. Seules les correspondances valides ont été conservées.

Les joueurs initialement complets et ceux enrichis ont ensuite été fusionnés afin d'obtenir un dataset cohérent.

Jointure avec les statistiques saisonnières

Une seconde jointure a été réalisée avec le dataset contenant les statistiques des joueurs par saison.

Cette jointure a été effectuée à l'aide de l'identifiant unique `PLAYER_ID`.

Ce dataset étant structuré au niveau saisonnier, une agrégation a été nécessaire afin d'obtenir un format adapté à la modélisation.

Nettoyage des données

Les joueurs présentant plusieurs valeurs différentes pour `DRAFT_OVERALL` ou `DRAFT_YEAR` ont été identifiés comme ambigus et supprimés.

Les divisions par zéro ont été évitées en remplaçant les valeurs nulles de `GP` par des valeurs manquantes lors du calcul des statistiques par match.

Construction des variables

Plusieurs variables dérivées ont été construites :

- `AGE_AT_SEASON` : âge du joueur à chaque saison ;
- `BMI_PROXY` : indicateur de corpulence ;
- `P_PER_GP` : points par match ;
- `G_PER_GP` : buts par match ;
- `A_PER_GP` : passes par match ;
- `PIM_PER_GP` : pénalités par match.

Le résultat de cette étape correspond à un fichier intermédiaire nommé `statistiques`, qui contient l'ensemble des données enrichies au niveau saisonnier avant agrégation.

Agrégation au niveau joueur

Une agrégation a été réalisée afin d'obtenir une seule ligne par joueur.

Les variables construites incluent :

- des variables statiques ;
- des statistiques cumulées ;
- des statistiques descriptives ;
- des variables de dernière saison ;
- des variables de carrière ;
- une variable de progression.

Description du dataset final

Le dataset final contient une seule ligne par joueur.

Il regroupe les caractéristiques individuelles, les performances agrégées avant la draft ainsi que la variable cible `DRAFT_OVERALL`.

Au total, le dataset contient **3583 joueurs** et **34 variables**. Le dataset final a été exporté sous le nom `dataset_joueur_draft.xlsx`. Ce fichier constitue la base utilisée pour les analyses et la

modélisation.

Description des variables du dataset final

Le dataset final contient les variables suivantes :

Variable	Description
PLAYER_ID	Identifiant unique du joueur.
DRAFT_OVERALL	Rang global de sélection du joueur lors de la draft. C'est la variable cible.
DRAFT_YEAR	Année de draft du joueur.
PRIMARY_POS	Position principale du joueur.
SECONDARY_POS	Position secondaire du joueur, si disponible.
NATIONALITY	Nationalité du joueur.
SHOOTS	Main de tir du joueur.
HEIGHT_CM	Taille du joueur en centimètres.
WEIGHT_KG	Poids du joueur en kilogrammes.
BMI_PROXY	Indicateur approximatif de corpulence calculé à partir de la taille et du poids.
AGE_LAST_SEASON	Âge du joueur lors de sa dernière saison observée avant la draft.
N_PRE_DRAFT_SEASONS	Nombre de saisons jouées avant la draft.
N_LEAGUES	Nombre de ligues différentes dans lesquelles le joueur a évolué avant la draft.
TOTAL_GP	Nombre total de matchs joués avant la draft.
TOTAL_G	Nombre total de buts marqués avant la draft.
TOTAL_A	Nombre total de passes réalisées avant la draft.
TOTAL_P	Nombre total de points obtenus avant la draft.
TOTAL_PIM	Nombre total de minutes de pénalité avant la draft.
MEAN_PPG	Moyenne des points par match sur les saisons observées.
MAX_PPG	Meilleure valeur de points par match atteinte sur une saison.
LAST_GP	Nombre de matchs joués lors de la dernière saison avant la draft.
LAST_G	Nombre de buts marqués lors de la dernière saison avant la draft.
LAST_A	Nombre de passes réalisées lors de la dernière saison avant la draft.
LAST_P	Nombre de points obtenus lors de la dernière saison avant la draft.
LAST_PPG	Points par match lors de la dernière saison avant la draft.
LAST_PIM	Minutes de pénalité lors de la dernière saison avant la draft.
LAST_PLUS_MINUS	Différentiel plus-moins du joueur lors de sa dernière saison.
LAST_LEAGUE	Ligue dans laquelle le joueur évoluait lors de sa dernière saison.
LAST_SEASON	Dernière saison observée avant la draft.
LAST_P_PER_GP	Points par match lors de la dernière saison.
LAST_G_PER_GP	Buts par match lors de la dernière saison.
LAST_A_PER_GP	Passes par match lors de la dernière saison.
LAST_PIM_PER_GP	Minutes de pénalité par match lors de la dernière saison.
DELTA_PPG_LAST_PREV	Variation des points par match entre la dernière saison et la saison précédente.

TABLE 1 – Description des variables du dataset final.

Adaptation du jeu de données pour le modèle Random Forest

Enfin, une seconde étape d'agrégation a été réalisée à partir du fichier intermédiaire **statistiques** afin de construire de nouvelles variables spécifiquement pour l'implémentation d'un modèle de type Random Forest.

Le dataset ainsi obtenu a été exporté sous le nom **randomforest.xlsx**.

Ces variables supplémentaires visent à mieux capturer certaines caractéristiques des performances des joueurs et à améliorer la capacité de généralisation du modèle.

Les variables ainsi construites sont décrites et justifiées dans les sections dédiées du rapport.