



UNIVERSITÉ LAVAL

**Prédire le rang de repêchage dans la LNH, analyse comparative du volume et
de l'efficacité des performances avant repêchage**

Réalisé par:
Benoît Daigle
Papa Garba Coulibaly
Fabrice Potvin
Mohamed Mbaye

Présenté à:
Steven Golovkine

Dans le cadre du cours
STT-7335: Méthodes d'analyse de données

Université Laval
Vendredi 24 Avril 2026

Déclaration sur l'IA

Des outils d'intelligence artificielle ont été utilisés ponctuellement pour améliorer la qualité visuelle de certaines figures (notamment avec seaborn), ainsi que pour le formatage du code et la correction rédactionnelle (fautes et mise en page).

Contents

1	Introduction	3
2	Mesures du volume et de l'efficacité	3
3	Analyse en composante principale	4
3.1	Objectif et justification	4
3.2	Préparation des données	4
3.3	Choix du nombre de composantes	4
3.4	Interprétation des composantes	5
3.5	Analyse des résultats par groupe de repêchage	6
3.6	Limites de l'ACP	7
4	Analyse exploratoire des données	7
4.1	Analyse des valeurs manquantes	7
4.2	Nettoyage des données	8
4.3	Statistiques descriptives	8
4.4	Distribution du rang de repêchage	9
4.5	Distribution des variables de performance	10
4.6	Analyse des corrélations	11
4.7	Relation entre performance et rang de repêchage	12
4.8	Synthèse	13
5	Modélisation par régression linéaire	13
5.1	Modèles simples : comparaison volume et efficacité	13
5.2	Modèles avec variable de contrôle	14
5.3	Modèle complet	15
5.4	Conclusion	16
6	Modèle de forêt aléatoire	16
6.1	Préparation des données	16
6.2	Colinéarité des variables	17
6.3	Ajustement du modèle	19
6.4	Analyse des résultats	20
7	Synthèse	21

1 Introduction

Le processus de sélection des joueurs lors du repêchage repose en partie sur l'analyse de leurs performances passées. Ces performances peuvent être évaluées selon deux dimensions principales : le volume, qui correspond à la quantité totale de statistiques accumulées, et l'efficacité, qui mesure la performance par match.

Cette étude comprend trois approches complémentaires : une analyse en composantes principales (ACP) pour explorer la structure des données, des modèles de régression linéaire pour quantifier l'effet de chaque dimension, et un modèle de forêt aléatoire pour évaluer le potentiel prédictif. L'objectif est de déterminer si le volume ou l'efficacité des performances avant repêchage est plus déterminant pour expliquer le rang de sélection, et d'identifier les variables les plus influentes dans ce processus.

2 Mesures du volume et de l'efficacité

Le jeu de données initial a été formé à partir de la combinaison de trois jeux de données distincts, un premier couvrant les informations de repêchage, un deuxième les informations sur les joueurs et un troisième avec les statistiques de jeu.

Les différentes analyses reposent sur ce jeu de données agrégé au niveau des joueurs, où chaque observation correspond à un joueur sélectionné lors du repêchage. La variable cible est le rang de repêchage (`DRAFT_OVERALL`). Le traitement du jeu de données a été adapté pour chaque analyse, avec une sélection spécifique des variables explicatives en fonction de l'approche méthodologique adoptée. Les variables explicatives sont regroupées en deux catégories principales :

Le volume de performance est mesuré à l'aide du nombre total de points (`TOTAL_P`), ainsi que, de manière complémentaire, du nombre de buts (`TOTAL_G`) et de passes (`TOTAL_A`).

L'efficacité est mesurée par les points par match. La variable `MEAN_PPG` correspond à la moyenne des points par match calculée sur chaque saison, c'est-à-dire à la moyenne des PPG saisonniers pour un joueur. La performance lors de la dernière saison (`LAST_PPG`) et la meilleure performance observée (`MAX_PPG`) sont également considérées.

Enfin, le nombre total de matchs joués (`TOTAL_GP`) est utilisé comme variable de contrôle afin de tenir compte de l'exposition au jeu. Ce jeu de données constitue la base utilisée dans les analyses suivantes, avec des sélections et traitements spécifiques des variables selon les besoins méthodologiques de chaque approche.

3 Analyse en composante principale

3.1 Objectif et justification

L'analyse en composantes principales (ACP) a été réalisée dans un objectif exploratoire, afin de réduire la dimensionnalité du jeu de données et d'examiner si les variables de performance avant le repêchage permettent de distinguer les joueurs selon leur rang de sélection. Elle est particulièrement adaptée pour identifier les axes principaux de variation et pour visualiser les relations entre les variables et les observations. Dans le contexte du repêchage de la LNH, l'ACP peut révéler des dimensions latentes associées au volume et à l'efficacité des performances avant repêchage, et évaluer si ces dimensions sont liées au rang de sélection.

3.2 Préparation des données

L'ACP a été appliquée à un ensemble de 11 variables quantitatives couvrant trois dimensions : la performance offensive par match (`LAST_P_PER_GP`, `LAST_G_PER_GP`, `LAST_A_PER_GP`, `LAST_PLUS_MINUS`, `DELTA_PPG_LAST_PREV`), la carrière avant repêchage agrégée (`MEAN_PPG`, `TOTAL_P`, `LAST_GP`) et les caractéristiques contextuelles (`AGE_LAST_SEASON`, `HEIGHT_CM`, `WEIGHT_KG`).

Pour choisir les variables à inclure dans l'ACP, on a d'abord calculé un score F pour chacune afin d'évaluer leur capacité à distinguer les groupes de repêchage. Le score F mesure le ratio entre la variance des moyennes entre les groupes et la variance à l'intérieur des groupes : plus il est élevé, plus la variable discrimine bien les groupes. Les variables trop corrélées entre elles ont été retirées pour éviter de fournir la même information en double : par exemple, `TOTAL_G` et `TOTAL_A` ont été remplacées par `TOTAL_P` qui les résume, et les statistiques absolues ont cédé leur place aux ratios par match pour ne pas avantager les joueurs ayant simplement joué plus de matchs. Les rares valeurs manquantes ont été remplacées par la médiane. L'ensemble des variables a ensuite été standardisé (moyenne nulle, écart-type unitaire) avant l'application de l'ACP, conformément aux exigences de la méthode.

3.3 Choix du nombre de composantes

La figure 1 présente le diagramme des valeurs propres (scree plot) en variance cumulée. On observe que la première composante explique à elle seule environ 41% de la variance totale, et que les quatre premières composantes en capturent environ 76%. Le coude du scree plot se situe entre la deuxième et la troisième composante, suggérant que l'essentiel de l'information est concentré dans les premières dimensions. Trois composantes ont donc été retenues pour l'interprétation.

3.4 Interprétation des composantes




Figure 1: Résultats de l'analyse en composantes principales.

Le cercle de corrélation (figure 1, figure en bas à gauche) permet d'identifier la signification des axes principaux. La première composante (PC1) est fortement associée aux variables de performance offensive par match : `LAST_A_PER_GP`, `LAST_P_PER_GP`, `TOTAL_P` et `MEAN_PPG` présentent toutes des contributions positives importantes sur cet axe. PC1 peut donc être interprété comme un axe d'efficacité offensive, opposant les joueurs à forte production relative aux joueurs moins productifs. Les variables de gabarit physique (`HEIGHT_CM`, `WEIGHT_KG`) sont quant à elles orientées négativement sur PC1, indiquant qu'elles sont orthogonales à la production offensive. La deuxième composante (PC2) capte principalement la dimension physique, avec `HEIGHT_CM` et `WEIGHT_KG` qui y contribuent positivement. Elle oppose ainsi les joueurs de grand gabarit aux joueurs plus légers, indépendamment de leur production. PC2 peut être interprété comme un axe de gabarit physique, distinct de la dimension d'efficacité capturée par PC1. La troisième composante (PC3) se distingue de PC1 par l'importance de `DELTA_PPG_LAST_PREV` et `LAST_GP`, qui y contribuent fortement, ainsi que de `AGE_LAST_SEASON`, orienté négativement. PC3 peut ainsi être interprété comme un axe relatif à la progression et l'âge des joueurs, opposant les jeunes joueurs en amélioration aux joueurs plus expérimentés mais moins dynamiques. La variable `AGE_LAST_SEASON` présente une faible projection dans le plan PC1 et PC2, ce qui indique qu'elle contribue davantage à

des composantes supérieures, notamment PC3.

Enfin, la projection sur PC1 et PC2 montre un chevauchement très important entre les trois groupes. Une interprétation des résultats basée uniquement sur cette projection est donc difficile. On pourra cependant étudier statistiquement la séparation des groupes sur les différentes composantes, et notamment sur PC1 qui semble la plus pertinente pour différencier les groupes de repêchage.

3.5 Analyse des résultats par groupe de repêchage

Afin d'évaluer la pertinence de l'ACP pour distinguer les groupes de sélection, les joueurs ont été répartis en trois catégories selon leur rang de repêchage : *Top 32* (premier tour), *33-100* (deuxièmes et troisièmes rondes) et *> 100* (rondes suivantes). Cette segmentation repose sur une logique propre au repêchage de la LNH, où la première ronde concentre les prospects les mieux identifiés et constitue une frontière naturelle.

Le tableau 1 présente les statistiques descriptives des scores sur PC1 pour chacun des trois groupes.

Groupe	Moyenne PC1	Écart-type	N
Top 32	+0,777	2,264	754
33-100	-0,012	2,033	1129
> 100	-0,336	2,040	1700

Table 1: Scores moyens sur PC1 par groupe de repêchage

On observe que les joueurs du premier tour se démarquent clairement des autres avec un score moyen de 0,8 tandis que les deux autres groupes affichent des scores négatifs. L'écart est particulièrement marqué entre le Top 32 et le groupe 33-100 ($\Delta = 0,79$), ce qui reflète bien la réalité du repêchage où la première ronde concentre les prospects les mieux identifiés. La différence entre les groupes 33-100 et > 100 est plus faible ($\Delta = 0,32$), ce qui est cohérent avec le caractère plus aléatoire des rondes suivantes.

Une analyse de variance (ANOVA) à un facteur a été réalisée sur les scores PC1. Il s'agit d'un test statistique qui évalue si les moyennes de plusieurs groupes sont significativement différentes les unes des autres. Cette analyse confirme que ces différences sont statistiquement significatives ($F = 74,31$, $p = 2,39 \times 10^{-32}$) où F confirme que la variance entre les groupes est bien supérieure à la variance à l'intérieur des groupes, et p indique que la probabilité d'observer une telle séparation par hasard est pratiquement nulle. Ce résultat confirme que PC1 capte un signal réel lié au rang de repêchage.




Figure 2: Distribution des scores sur PC1, PC2 et PC3 par groupe de repêchage.

La figure 2 présente les distributions de densité des scores sur PC1, PC2 et PC3 pour chaque groupe. Sur PC1, on observe un décalage visible de la distribution du groupe Top 32 vers des valeurs plus élevées, tandis que les groupes 33-100 et > 100 se chevauchent davantage. Sur PC2 et PC3, les distributions sont quasi identiques entre groupes, confirmant que ces composantes ne contribuent pas à la discrimination par rang de repêchage et reflètent d'autres sources de variabilité (gabarit physique, âge).

3.6 Limites de l'ACP

Le chevauchement important des nuages de points dans la projection PC1-PC2 (figure 1) ne constitue pas un défaut de l'analyse, mais reflète la nature même du processus de repêchage. L'ACP, méthode non supervisée, maximise la variance globale et non la séparation entre groupes. Le chevauchement observé traduit le bruit inhérent au repêchage : des joueurs aux statistiques similaires peuvent être sélectionnés à des rangs très différents selon des critères non observables (performances aux camps d'entraînement, profil athlétique, positionnement tactique). Ces limites motivent le recours aux modèles supervisés présentés aux sections suivantes.

4 Analyse exploratoire des données

L'analyse exploratoire vise à comprendre la structure des données ainsi que les premières relations entre les variables et le rang de repêchage. Les modèles de régression présentés dans cette section reposent sur un sous-ensemble plus restreint de variables que l'ACP, centré explicitement sur le volume et l'efficacité qui constituent l'objet de l'étude. Tandis que l'ACP visait une exploration large de la structure des données, la régression cherche à quantifier l'effet marginal de chaque dimension sur le rang de repêchage.

4.1 Analyse des valeurs manquantes

Le jeu de données a fait l'objet de plusieurs étapes de prétraitement afin de garantir la cohérence de l'analyse. Une analyse des valeurs manquantes a été réalisée sur les principales variables utilisées dans l'étude. Le tableau 2 présente le nombre de valeurs manquantes pour chaque variable.

Variable	Nombre de valeurs manquantes
DRAFT_OVERALL	0
TOTAL_P	0
TOTAL_G	0
TOTAL_A	0
MEAN_PPG	2
LAST_PPG	2
MAX_PPG	2
TOTAL_GP	0

Table 2: Nombre de valeurs manquantes par variable

On observe que seules les variables d'efficacité présentent des valeurs manquantes, en nombre très limité. Les valeurs manquantes des variables d'efficacité ont été imputées à l'aide de la médiane. Ce choix permet de conserver l'ensemble des observations tout en limitant l'influence des valeurs extrêmes, les distributions étant asymétriques. La médiane, plus robuste que la moyenne face aux valeurs atypiques, est donc adaptée dans ce contexte. Cette approche reste une approximation, car elle suppose que les valeurs manquantes sont proches du comportement central des données.

Variable	Nombre de valeurs manquantes	Valeur imputée (médiane)
MEAN_PPG	2	0.519
LAST_PPG	2	0.645
MAX_PPG	2	0.710

Table 3: Imputation des valeurs manquantes par la médiane

4.2 Nettoyage des données

Les joueurs ne disposant d'aucune statistique de performance, notamment ceux n'ayant disputé aucun match ($TOTAL_GP = 0$), ont été exclus du jeu de données. En effet, leur rang de repêchage ne peut pas être expliqué par les variables étudiées.

Après prétraitement, le jeu de données final contient 3560 joueurs décrits par 8 variables numériques.

4.3 Statistiques descriptives

Le tableau 4 présente les principales statistiques descriptives des variables utilisées dans l'étude.

Variable	Moyenne	Écart-type	Min	Max
DRAFT_OVERALL	103.06	70.77	1	290
TOTAL_P	62.92	54.88	0	466
TOTAL_G	24.41	24.43	0	215
TOTAL_A	38.53	32.68	0	274
MEAN_PPG	0.61	0.46	0	3.48
LAST_PPG	0.73	0.53	0	3.60
MAX_PPG	0.82	0.60	0	4.13
TOTAL_GP	91.30	51.76	1	468

Table 4: Statistiques descriptives des variables

Les variables de volume (TOTAL_P, TOTAL_G, TOTAL_A) présentent une forte dispersion, avec des valeurs maximales élevées. Les variables d'efficacité sont plus concentrées, tandis que TOTAL_GP montre une variabilité importante du nombre de matchs disputés.

4.4 Distribution du rang de repêchage

La figure 3 présente la distribution du rang de repêchage.




Figure 3: Distribution du rang de repêchage

On observe une concentration plus importante d'observations dans les premiers rangs du repêchage, tandis que les rangs élevés sont moins représentés. La distribution est relativement étalée, avec une diminution progressive du nombre d'observations lorsque le rang augmente.

4.5 Distribution des variables de performance

La figure 4 présente la distribution des variables de volume et d'efficacité.




Figure 4: Distribution des variables de volume et d'efficacité

Les variables de volume (TOTAL_P, TOTAL_G, TOTAL_A) présentent une forte asymétrie, avec une majorité de joueurs ayant des performances modestes et un nombre limité de joueurs affichant des valeurs élevées. La variable TOTAL_GP présente également une dispersion importante, traduisant une forte variabilité du nombre de matchs disputés par les joueurs. Les variables d'efficacité (MEAN_PPG, LAST_PPG, MAX_PPG) sont quant à elles plus concentrées, avec une dispersion plus faible, bien que certaines valeurs élevées correspondent à des performances exceptionnelles. Ces résultats suggèrent que les variables d'efficacité sont plus stables que les variables de volume, et pourraient donc être plus pertinentes pour expliquer le rang de repêchage.

4.6 Analyse des corrélations

La figure 5 présente les corrélations entre les variables et le rang de repêchage.




Figure 5: Corrélation des variables avec le rang de repêchage

On observe que les variables d'efficacité, en particulier **LAST_PPG**, présentent une corrélation plus forte (en valeur absolue) avec le rang de repêchage que les variables de volume. À l'inverse, le nombre de matchs joués (**TOTAL_GP**) présente une corrélation très faible. La matrice de corrélation (figure 6) met en évidence une forte corrélation entre les variables de volume (**TOTAL_P**, **TOTAL_G**, **TOTAL_A**). Cette corrélation confirme la redondance entre ces variables, qui s'explique par leur relation directe, puisque $TOTAL_P = TOTAL_G + TOTAL_A$. Par conséquent, seules les variables les plus représentatives ont été conservées pour la suite de l'analyse, et la variable **TOTAL_P** a été retenue comme indicateur du volume de performance. Les variables d'efficacité mesurent la performance relative des joueurs par match : la moyenne des points par match (**MEAN_PPG**), la performance lors de la dernière saison (**LAST_PPG**) et la meilleure performance observée (**MAX_PPG**). Ces variables présentent également des corrélations entre elles, traduisant des informations proches mais non strictement équivalentes.

Enfin, la variable **TOTAL_GP** correspond au nombre total de matchs disputés par un joueur. Elle présente des corrélations plus faibles avec les autres variables, ce qui suggère qu'elle capture une dimension différente liée à l'exposition au jeu.

Ces observations permettent de guider la sélection des variables pour la suite de l'analyse.




Figure 6: Matrice de corrélation des variables

4.7 Relation entre performance et rang de repêchage

La figure 7 présente la relation entre les variables étudiées et le rang de repêchage.




Figure 7: Relation entre le volume, l'efficacité et le rang de repêchage

Les graphiques mettent en évidence une relation négative entre les performances des joueurs et leur rang de repêchage : lorsque les performances augmentent, le rang de repêchage tend à diminuer, indiquant une meilleure sélection. Cette relation apparaît toutefois plus marquée pour les variables d'efficacité que pour les variables de volume. En particulier, la performance lors de la dernière saison (**LAST_PPG**) semble présenter une relation plus nette avec le rang de repêchage. La dispersion observée, notamment pour les variables de volume, suggère que ces dernières expliquent moins bien le rang de repêchage. À l'inverse, les variables d'efficacité présentent une relation plus structurée, ce qui indique qu'elles pourraient constituer de meilleurs prédicteurs du rang de repêchage.

4.8 Synthèse

L'analyse exploratoire met en évidence que les variables d'efficacité, et en particulier la performance lors de la dernière saison, semblent plus informatives que les variables de volume pour expliquer le rang de repêchage. Ces observations motivent la mise en place de modèles de régression linéaire afin de quantifier l'influence respective du volume et de l'efficacité, ainsi que d'évaluer leur contribution conjointe.

5 Modélisation par régression linéaire

Afin de quantifier l'influence des différentes variables sur le rang de repêchage, plusieurs modèles de régression linéaire ont été estimés. Dans un premier temps, des modèles simples ont été considérés afin d'évaluer séparément l'effet du volume et de l'efficacité. Le volume est représenté par la variable **TOTAL_P**, tandis que l'efficacité est mesurée à l'aide de **MEAN_PPG**, **LAST_PPG** et **MAX_PPG**. Dans un second temps, des modèles incluant une variable de contrôle (**TOTAL_GP**) ont été estimés afin de tenir compte du nombre de matchs disputés, susceptible d'influencer les variables de volume.

Enfin, un modèle complet intégrant l'ensemble des variables retenues a été construit afin d'analyser leur effet conjoint et d'identifier les variables les plus influentes.

5.1 Modèles simples : comparaison volume et efficacité

Les modèles de régression linéaire simples estimés sont les suivants :

$$\text{DRAFT_OVERALL} = \beta_0 + \beta_1 \cdot X + \varepsilon$$

où X représente successivement les variables de volume et d'efficacité.

Le tableau 5 présente les résultats obtenus.

Variable	R^2	Coefficient
TOTAL_P (volume)	0.0226	-0.194
MEAN_PPG (efficacité moyenne)	0.0313	-26.934
LAST_PPG (efficacité récente)	0.0433	-27.790
MAX_PPG (pic de performance)	0.0236	-18.082

Table 5: Résultats des modèles simples

On observe que toutes les variables présentent une relation négative avec le rang de repêchage, indiquant que de meilleures performances sont associées à un meilleur rang. Le coefficient associé à TOTAL_P (-0.194) indique qu'un point supplémentaire est associé à une amélioration moyenne de 0.194 position dans le rang de repêchage. En revanche, les variables d'efficacité présentent des effets plus marqués : une augmentation d'un point par match est associée à une amélioration d'environ 27 positions pour MEAN_PPG et LAST_PPG, et d'environ 18 positions pour MAX_PPG. En termes de pouvoir explicatif, LAST_PPG présente la valeur de R^2 la plus élevée, suivie de MEAN_PPG, tandis que TOTAL_P et MAX_PPG présentent des performances similaires mais plus faibles. Ces résultats montrent que les variables d'efficacité expliquent mieux le rang de repêchage que le volume, et que la performance récente constitue l'indicateur le plus pertinent parmi ceux étudiés.

5.2 Modèles avec variable de contrôle

Afin de tenir compte du nombre de matchs disputés, des modèles incluant la variable de contrôle TOTAL_GP ont été estimés :

$$\text{DRAFT_OVERALL} = \beta_0 + \beta_1 \cdot \text{TOTAL_P} + \beta_2 \cdot \text{TOTAL_GP} + \varepsilon$$

$$\text{DRAFT_OVERALL} = \beta_0 + \beta_1 \cdot \text{MEAN_PPG} + \beta_2 \cdot \text{TOTAL_GP} + \varepsilon$$

Les résultats sont présentés dans le tableau 6.

Modèle	R^2	Coefficient variable principale	Coefficient TOTAL_GP
Volume + contrôle	0.0370	-0.335	0.222
Efficacité + contrôle	0.0314	-27.182	0.016

Table 6: Résultats des modèles avec variable de contrôle

Dans le modèle de volume, le coefficient de TOTAL_P devient plus important en valeur absolue

(-0.335 contre -0.194 précédemment), tandis que **TOTAL_GP** présente un coefficient positif (0.222). Cela indique qu'à volume donné, un plus grand nombre de matchs est associé à un rang de repêchage moins favorable.

Dans le modèle d'efficacité, le coefficient de **MEAN_PPG** reste stable (-27.182 contre -26.934), tandis que l'effet de **TOTAL_GP** est très faible (0.016). Ces résultats montrent que le volume est fortement influencé par le nombre de matchs disputés, alors que l'efficacité constitue une mesure plus robuste, peu affectée par cette variable de contrôle.

5.3 Modèle complet

Enfin, un modèle de régression linéaire intégrant l'ensemble des variables retenues a été estimé :

$$\text{DRAFT_OVERALL} = \beta_0 + \beta_1 \cdot \text{TOTAL_P} + \beta_2 \cdot \text{MEAN_PPG} + \beta_3 \cdot \text{LAST_PPG} + \beta_4 \cdot \text{MAX_PPG} + \beta_5 \cdot \text{TOTAL_GP} + \varepsilon$$

Les résultats sont présentés dans le tableau 7.

Variable	Coefficient
LAST_PPG	-31.565
MAX_PPG	19.813
MEAN_PPG	-2.088
TOTAL_P	-0.250
TOTAL_GP	0.192

Table 7: Résultats du modèle complet ($R^2 = 0.0531$)

Dans ce modèle, la variable **LAST_PPG** apparaît comme la plus influente, avec un coefficient négatif important, confirmant que la performance récente joue un rôle central dans le rang de repêchage. À l'inverse, le coefficient associé à **MEAN_PPG** devient faible, ce qui suggère que son effet est en grande partie capturé par **LAST_PPG**. De même, l'effet de **TOTAL_P** reste limité. Le coefficient positif de **MAX_PPG** indique qu'à performance récente donnée, un pic de performance isolé est associé à un rang de repêchage moins favorable, ce qui suggère que les recruteurs privilégient la régularité ou la performance récente plutôt qu'un pic ponctuel. Enfin, **TOTAL_GP** conserve un effet positif, indiquant qu'un plus grand nombre de matchs est associé à un rang légèrement moins favorable. Le modèle complet confirme que la performance lors de la dernière saison constitue le facteur le plus déterminant, tandis que les autres variables jouent un rôle secondaire ou capturent des effets redondants. Toutefois, la faible valeur de R^2 indique que le rang de repêchage reste faiblement expliqué par les variables considérées.

5.4 Conclusion

Ainsi, cette étude met en évidence que l'efficacité, et plus particulièrement la performance récente, constitue un meilleur indicateur du rang de repêchage que le volume de performance. Toutefois, le faible pouvoir explicatif global des modèles linéaires indique que d'autres facteurs non observés jouent un rôle important, ce qui motive le recours à une approche non paramétrique présentée à la section suivante.

6 Modèle de forêt aléatoire

La forêt aléatoire prolonge l'analyse en introduisant des variables enrichies absentes des sections précédentes, notamment `NHLe_PPG` qui pondère la production selon la difficulté de la ligue, et `EXACT_AGE_AT_DRAFT` qui affine la mesure de maturité. Ces ajouts visent à corriger deux limites identifiées dans les modèles linéaires : la non-comparabilité des statistiques entre ligues et l'arrondissement de l'âge.

6.1 Préparation des données

Le script « `process_data.py` » applique plusieurs modifications similaires aux jeux de données précédents, mais avec certaines variantes afin d'adapter les besoins du modèle. Pour celui-ci, il a aussi été décidé de garder les statistiques du joueur pour l'année précédant son repêchage. Notre précédente modélisation indique que les performances les plus récentes auront généralement un plus grand impact sur le rang auquel le joueur sera repêché.

Une fois que les données sont regroupées de sorte qu'une ligne correspond à un joueur, on peut calculer certaines variables plus informatives. Notamment, le « `SNIPER_RATIO` » qui calcule la proportion de points qui sont des buts. Ensuite, le « `MOMENTUM_PPG` » qui montre comment la production d'un joueur s'est améliorée dans sa dernière année par rapport à ses autres saisons. De plus, il y a le « `PLAYMAKER_RATIO` » qui représente la proportion de points qui sont des passes. Finalement, les variables les plus informatives sont « `NHLe_PPG` » et « `EXACT_AGE_AT_DRAFT` ». La première se base sur le fait qu'un même nombre de points dans des ligues différentes ne vaut pas le même poids. Par exemple, il est inexact d'affirmer que 60 points dans la ligue russe (KHL) est équivalent à 60 points dans la ligue universitaire américaine (NCAA). En effet, la ligue russe est beaucoup plus difficile, donc on devrait accorder plus d'importance à une production équivalente dans celle-ci. La deuxième variable indique l'âge exact, en nombre à virgule, que le joueur a au moment du repêchage qui se déroule généralement autour du 25 juin. Plus tôt dans le projet, l'âge arrondi à l'entier le plus proche était considéré. Cette variable permet d'avoir une meilleure précision et plus de détails sur l'âge. Voici les poids utilisés, ceux-ci étant basés sur l'article de Patrick Bacon¹ :

¹BACON Patrick, «NHL Equivalency and Prospect Projection Models: Building the NHL Equivalency Model (Part 2)», *TDS Archive*, 2021

```

nhle_weights = {
  'KHL': 0.80,      # Ligue russe
  'SHL': 0.58,      # Ligue suédoise
  'CZECH': 0.45,    # Extraliga tchèque
  'NLA': 0.43,      # Ligue suisse
  'LIIGA': 0.43,     # Ligue finlandaise
  'DEL': 0.38,      # Ligue allemande
  'NCAA': 0.33,     # Universitaire américain
  'OHL': 0.32,      # Junior Ontario
  'WHL': 0.29,      # Junior Ouest
  'USHL': 0.27,     # Junior Américain
  'QMJHL': 0.26,    # Junior Québec
  'BCHL': 0.17,     # Junior A (Colombie-Britannique)
  'AJHL': 0.15,     # Junior A (Alberta)
  'OJHL': 0.11,     # Junior A (Ontario)
  'NOJHL': 0.10,    # Junior A (Nord de l'Ontario)
  'USHS-MN': 0.09,  # High School (Minnesota)
  'USHS-PREP': 0.08 # Prep School (USA)
}

```

Figure 8: Poids pour chaque ligue

Un dernier nettoyage des données a ensuite été effectué afin d'assurer l'absence de valeur « NA ». De plus, afin de garantir un modèle plus stable, le modèle se concentre sur les choix des deux premières rondes du repêchage. En effet, après les deux ou trois premières rondes, le rang de repêchage devient très imprévisible. Les équipes aiment tenter leur chance avec des joueurs qu'elles apprécient, sans nécessairement qu'ils se distinguent statistiquement des autres. Cela devient difficile pour notre modèle d'être précis, car il y a trop de bruit. La dernière modification apportée au jeu de données est de ne garder que les joueurs ayant joué au moins 5 matchs, pour avoir un certain échantillon. Les variables finales qui ont été gardées pour le modèle sont présentées ci-dessous :

```

colonnes_finales = [
  "PLAYER_ID", "DRAFT_OVERALL", "DRAFT_YEAR", "PRIMARY_POS", "NATIONALITY",
  "SHOOTS", "WEIGHT_KG", "HEIGHT_CM", "BMI_PROXY", "TOTAL_GP", "GP6", "AP6",
  "PP6", "PIM_PP6", "MAX_PP6", "LAST_GP", "LAST_LEAGUE", "SNIPER_RATIO",
  "LAST_6_PER_GP", "LAST_P_PER_GP", "LAST_A_PER_GP", "LAST_PIM_PER_GP",
  "MOMENTUM_PP6", "PLAYMAKER_RATIO", "EXACT_AGE_AT_DRAFT", "NHLe_PP6"
]

```

Figure 9: Liste des variables après traitement

6.2 Colinéarité des variables

Nous pouvons maintenant passer au script « Foret_aleatoire » qui se concentre sur le choix final des variables et sur les réglages du modèle. Avant même d'entraîner le modèle, nous retirons les variables colinéaires, pour éviter de fournir la même information. Le premier graphique montre les corrélations entre les variables :




Figure 10: Corrélations des variables

On peut tout de suite remarquer qu'il y a beaucoup de variables qui sont corrélées, notamment « PLAYMAKER_RATIO » et « SNIPER_RATIO », car leur somme est égale à 1. Nous avons décidé de seulement garder la première. Ensuite, les variables d'indice corporel sont assez corrélées entre elles, donc nous avons décidé de garder le poids et la taille, mais de retirer « BMI_PROXY ». Pour continuer, tous les indicateurs de points, buts et passes sont assez corrélés. Cela dit, en nous basant sur notre analyse précédente, nous avons décidé de retirer « PPG », « GPG », « MAX_PPG », « LAST_G_PER_GP », « LAST_A_PER_GP » et « APG » pour garder « LAST_P_PER_GP » qui résume bien toutes ces variables. De plus, nous avons décidé de retirer « PIM_PPG » pour conserver « LAST_PIM_PER_GP ». Nous avons calculé de nouveau les corrélations pour voir une nette amélioration :




Figure 11: Corrélations après sélection des variables

6.3 Ajustement du modèle

Pour notre modèle, il faut s'assurer de transformer les variables « PRIMARY_POS », « SHOOTS », « LAST_LEAGUE » et « NATIONALITY » en variables indicatrices pour traiter des valeurs numériques. Nous avons décidé de séparer notre jeu de données en 70/30, ce qui nous donne 862 données d'entraînement et 370 données de test. Pour choisir les bons paramètres du modèle, nous procédons par recherche en grille. Les différents paramètres testés sont les suivants :

```
grille_parametres = {
    'n_estimators': [300, 500, 700, 900],
    'max_depth': [5, 10, 15, None],
    'min_samples_leaf': [1, 2],
    'max_features': ['sqrt', 'log2', 0.4, 0.7],
    'criterion': ['squared_error', 'absolute_error', 'friedman_mse']
}
```

Figure 12: Grille des paramètres pour le modèle

6.4 Analyse des résultats

Une fois les meilleurs paramètres trouvés, nous pouvons analyser les résultats obtenus sur les données de test, notamment le MAE (erreur moyenne absolue), le RMSE (erreur quadratique moyenne) et le R^2 , qui sont respectivement de 13,36, 16,21 et 0,22. En moyenne, notre modèle se trompe d'environ 13 rangs sur ses prédictions. Le RMSE est une métrique similaire au MAE, mais il pénalise plus les grandes erreurs commises. Puisque cette métrique est plus élevée, on peut comprendre qu'on commet parfois des erreurs plus importantes sur les prédictions. Quant à lui, le coefficient R^2 nous indique que les variables de notre modèle permettent seulement d'expliquer environ 22% des variations du choix de repêchage. Les variables les plus importantes pour le modèle sont « NHL_PPG », « EXACT_AGE_AT_DRAFT » et « LAST_P_PER_GP », telles que présentées dans le graphique ci-dessous :




Figure 13: Importance de chaque variable

Nous pouvons aussi comparer les rangs prédits aux vrais rangs de repêchage avec le graphique suivant:




Figure 14: Prédictions du modèle vs vrais rangs de repêchage

En effet, on peut voir un nuage de points qui montre que le modèle semble avoir de la difficulté à prédire des rangs aux extrêmes. D'ailleurs, on peut remarquer qu'il n'y a aucune prédiction après le 48^e rang, mais il y a plusieurs prédictions dans les premiers rangs. On peut interpréter cela en comprenant que le modèle manque d'information qui lui permet de distinguer des joueurs de fin de deuxième ronde. De plus, cet algorithme sait que pour réduire le plus possible son erreur moyenne, il peut effectuer des prédictions près du milieu. C'est exactement ce qu'on voit avec des points répartis comme une bande horizontale autour du 32^e rang. Idéalement, on voudrait avoir notre nuage de points qui est collé sur la diagonale rouge $y = x$, qui nous indiquerait que le modèle ne fait aucune erreur.

De plus, il peut être intéressant d'observer la précision sur différents intervalles. Par exemple, sur les données de test, le modèle a su prédire seulement 13,51% des observations à plus ou moins 3 rangs de précision. Entre autres, seulement 62,43% des rangs ont été classés à une précision de plus ou moins 16. Les autres performances sont présentées ci-dessous :

```
Proportion de prédictions exactes à +/- 3 rangs : 13.51 %  
Proportion de prédictions exactes à +/- 5 rangs : 20.00 %  
Proportion de prédictions exactes à +/- 10 rangs : 42.43 %  
Proportion de prédictions exactes à +/- 16 rangs : 62.43 %
```

Figure 15: Succès de prédiction pour certains intervalles

7 Synthèse

Pour conclure sur le modèle de forêt aléatoire, les résultats montrent que l'algorithme atteint ses limites avec ce type de données fortement bruitées. Il adopte une approche conservatrice en concentrant ses prédictions autour du centre de la distribution, ce qui lui permet de minimiser l'erreur moyenne au détriment de la précision aux extrêmes. Par ailleurs, les variables disponibles ne sont pas suffisamment informatives pour capturer la complexité du processus de repêchage : des attributs comme les performances aux camps d'entraînement, la vitesse de pointe, la vision du jeu ou les batailles gagnées auraient probablement amélioré les résultats, mais ne sont pas accessibles gratuitement.

En regardant l'ensemble du travail, les trois analyses pointent dans la même direction. L'ACP montre qu'il existe bel et bien un signal dans les données avant repêchage, la régression linéaire confirme que ce signal vient surtout de l'efficacité récente ($LAST_PPG$, $R^2 = 0,043$) plutôt que du volume, et la forêt aléatoire, malgré un meilleur pouvoir prédictif ($R^2 = 0,22$), arrive aux mêmes conclusions : ses variables les plus importantes sont $NHLe_PPG$, $EXACT_AGE_AT_DRAFT$ et $LAST_P_PER_GP$, toutes des mesures d'efficacité ou de maturité. En somme, la qualité de la production prime sur la quantité, et l'âge au moment du repêchage est un facteur plus déterminant qu'on pourrait le croire.