

Détection de tumeurs cérébrales en IRM à l'aide de différentes modifications de YOLO

Noureddine Faleh¹, Benoit Daigle¹, Garip Akkaya¹, Ferdinand Daniel Koenig¹, Kokou Joel Agbogan¹

Abstract— Ce travail présente une exploration de différentes adaptations structurelles de la famille d'architectures YOLO (v8 et v11) conçues pour la détection et la localisation de tumeurs cérébrales sur IRM. L'approche proposée étudie l'impact de deux axes d'optimisation majeurs : l'intégration de mécanismes d'attention (PSA, C2PSA, CBAM) pour affiner l'extraction de caractéristiques complexes, et l'ajout d'une quatrième tête de détection à haute résolution (P2) couplée à une complexification du backbone (YOLOv11-HR-D) pour pallier les limites de détection des micro-lésions.

Sur un jeu de données contenant quatre classes (Gliome, Méningiome, Tumeur pituitaire et Sans tumeur), nos différentes expérimentations révèlent des comportements complémentaires. Si les mécanismes d'attention améliorent globalement le rappel clinique, les architectures à haute résolution (HR-D) surpassent les modèles de base dans la précision de la délimitation spatiale (mAP@50-95). Ces résultats démontrent qu'un compromis doit être fait entre confiance globale et précision géométrique stricte face à la variabilité texturale et morphologique des lésions diffuses.

Index Terms— Détection d'objets, YOLOv11, Haute Résolution (P2), C3k2, Mécanismes d'attention (PSA, CBAM), IRM cérébrale, Neuro-oncologie, Deep Learning médical.

I. INTRODUCTION

L'analyse automatique d'images IRM cérébrales constitue aujourd'hui un axe majeur de l'intelligence artificielle appliquée à la santé. Dans ce contexte, la détection de tumeurs présente des enjeux cliniques critiques : un faux négatif — une lésion non détectée — peut retarder un diagnostic vital et compromettre lourdement le pronostic du patient. Bien que les architectures modernes de la famille YOLO (*You Only Look Once*) soient performantes sur des images naturelles à fort contraste, l'imagerie IRM impose des contraintes spécifiques : frontières lésionnelles diffuses, faible contraste local et grande hétérogénéité anatomique inter-patients.

Le défi majeur réside dans la variabilité extrême de la morphologie tumorale. Un jeu de données standard confronte le réseau à des gliomes volumineux et infiltrants aussi bien qu'à de minuscules adénomes hypophysaires. L'architecture standard, souvent limitée à trois échelles de détection (P3, P4, P5), s'avère souvent insuffisante pour capturer ces lésions de très petite taille. Par ailleurs, la subtilité texturale des tissus

cérébraux requiert une capacité d'abstraction mathématique supérieure pour distinguer les anomalies du parenchyme sain.

Pour répondre à ces problématiques, ce projet explore l'évolution des performances depuis les modèles légers (YOLOv8n et YOLOv11n) vers des architectures optimisées telles que YOLOv11s et notre proposition **YOLOv11-HR-D** (basée sur la version *nano*). L'objectif est d'étudier l'impact isolé et conjoint de plusieurs modifications :

- 1) **Attention Spatiale et Sémantique** : Implémentation des modules PSA (*Position-Sensitive Attention*) et CBAM (*Convolutional Block Attention Module*).
- 2) **Haute Résolution** : Intégration d'une branche de prédiction P2 (stride 4) pour une sensibilité accrue aux micro-lésions.
- 3) **Extraction Profonde** : Activation des connexions résiduelles profondes (C3k2 *True*) pour mieux encoder les textures.

Cet article regroupe l'ensemble de ces expérimentations. Après avoir exposé l'état de l'art (Sec. II) et la méthodologie (Sec. III), nous détaillerons les modifications architecturales (Sec. IV) avant de présenter une analyse croisée et globale des résultats cliniques (Sec. V). L'usage de l'IA générative en support rédactionnel et de programmation sera détaillé en Section VI.

II. ÉTAT DE L'ART

A. Détection d'objets médicaux

L'analyse d'imagerie médicale par apprentissage profond a connu des avancées majeures ces dernières années [1]. Les architectures à ancres (Faster R-CNN [2]) ont longtemps dominé la détection médicale grâce à leur précision de localisation. Les architectures à une étape (YOLO, SSD) ont progressivement rattrapé ce niveau de précision tout en offrant des vitesses d'inférence bien supérieures, les rendant attractives pour les systèmes d'aide au diagnostic temps-réel [3]. YOLOv8 [4] et YOLOv11 [5] représentent l'état de l'art de cette famille avec une architecture *anchor-free*, une tête de détection découplée et un module SPPF (*Spatial Pyramid Pooling - Fast*) pour la perception multi-échelle.

B. Mécanismes d'attention pour la vision

SENet [6] introduit l'attention canal via un *squeeze-and-excitation network* qui recalibre les réponses des filtres convolutifs. CBAM [7] étend cette idée en ajoutant une attention spatiale orthogonale. Des variantes plus récentes, telles que

*This work was not supported by any organization

¹Faculté Sciences et génie, Université Laval, Québec (Québec) G1V 0A6, Canada {noureddine.faleh.1, benoit.daigle.1, garip.akkaya.1, ferdinand.koenig.1, kokou-joel.agbogan.1}@ulaval.ca

Triplet Attention [8], ont amélioré ces résultats sur des benchmarks naturels. En imagerie médicale, plusieurs travaux ont intégré des mécanismes d’attention dans des segmenteurs U-Net [9] avec des gains significatifs, suggérant que l’attention peut effectivement aider le réseau à focaliser sur des régions lésionnelles subtiles et hétérogènes.

III. MATÉRIEL ET MÉTHODES

A. Jeu de données et protocole

Toutes les expériences s'appuient principalement sur le *Brain Tumor Detection Dataset* [10] composé de 3 903 images IRM annotées par *bounding boxes*, réparties en quatre classes : Gliome, Méningiome, Tumeur pituitaire et Sans tumeur. Le dataset est fourni avec un split prédéfini : 2 444 images d'entraînement (63 %), 1 074 images de validation (28 %) et 385 images de test (10 %).

Exception pour YOLOv8n : les expériences impliquant **YOLOv8n** (baseline et variante CBAM) ont été conduites sur un second dataset annoté au format TensorFlow [11], composé de 1 956 images réparties en cinq classes (dont une classe *space-occupying lesion* absente du dataset principal) : 1 370 images d’entraînement, 395 de validation et 191 de test. Ce dataset présente un déséquilibre inter-classes notable (596 méningiomes contre seulement 149 gliomes en entraînement), ce qui doit être pris en compte lors de la comparaison directe des résultats YOLOv8n avec les autres familles de modèles.

Les métriques retenues pour l'évaluation sont la Précision, le Rappel, le F1-Score, le mAP@50 (sensibilité de détection) et le mAP@50-95 (rigueur de la localisation spatiale).

B. Détails d’entraînement

Afin de comparer rigoureusement les modèles, les hyperparamètres de base ont été maintenus aussi constants que possible. Tous les modèles ont été entraînés sur un **GPU Tesla T4** (Google Colab) pour 50 époques, en utilisant l’optimiseur **AdamW** avec un taux d’apprentissage initial compris entre 0.0005 et 0.001. Pour assurer la reproductibilité, une graine aléatoire (*seed*) a été fixée à 42.

Concernant l’augmentation de données, **RandAugment** a été maintenu actif tout au long de l’entraînement, avec des transformations incluant des rotations ($\pm 10^\circ$), des retournements horizontaux aléatoires, ainsi que des ajustements de luminosité et de contraste. **Mosaic** a quant à lui été appliqué durant les 40 premières époques puis désactivé afin de stabiliser la convergence en fin d’entraînement.

Note sur la résolution : en raison de la surcharge calculatoire induite par la séparation des flux d’attention, le modèle **YOLOv11n-PSA** a été entraîné à résolution réduite (512×512 , *batch* de 8) ; le mAP@50-95 n’a pas été calculé pour cette configuration en raison d’une incompatibilité de la version Ultralytics utilisée avec cette résolution réduite lors de l’évaluation IoU stricte. Les modèles **CBAM** et **HR-D** ont été entraînés à pleine résolution (640×640 , *batch* de 16). Chaque modèle modifié est systématiquement comparé à sa propre *baseline* de référence, entraînée dans des conditions identiques.

IV. MODIFICATIONS ARCHITECTURALES EXPLORÉES

A. Axe 1 : Mécanismes d'attention (PSA et CBAM)

1) *Module PSA dans YOLOv11n*: Le module PSA (*Position-Sensitive Attention*) permet de capturer le contexte global de l'image tout en restant léger calculatoirement. Cette légèreté est permise par une séparation des flux de tenseurs dans le code. Concrètement, la fonction *forward* débute avec un tenseur d'entrée x subissant une première convolution 1×1 . Ce tenseur est ensuite coupé en deux moitiés égales via l'opération `a, b = self.cv1(x).split(..., dim=1)`.

La moitié (a) est préservée intacte, tandis que l'autre (b) subit le mécanisme d'attention spatiale : $b = b + \text{self.attn}(b)$. Ensuite, ce même tenseur b subit une autre transformation en s'additionnant au résultat de son passage dans un réseau Feed-Forward : $b = b + \text{self.ffn}(b)$. L'étape finale concatène le tenseur original a (qui a préservé les détails bruts) avec le tenseur transformé b (caractéristiques globales), avant une ultime convolution.

Placement : L'insertion s'est faite après la couche C3K2 dans le *neck*, juste avant la première tête de détection (Figure 1). Ce placement est stratégique : l'analyse du modèle de base a révélé que la classe éprouvant le plus de difficultés de délimitation était celle des Gliomes (aux contours peu nets). Placer l'attention sur les détails fins à ce niveau précis aide le réseau à distinguer les frontières floues de ces lésions.




Fig. 1: Architecture modifiée de YOLOv11n avec l'ajout d'une couche d'attention PSA sur la tête de détection des petits détails.

2) *Module CBAM dans YOLOv8n et YOLOv11s*: Nous avons également testé l'intégration du *Convolutional Block Attention Module* (CBAM). Ce module introduit une attention séquentielle

combinant une attention canal et une attention spatiale (Figure 2).

- Sur **YOLOv8n**, le CBAM a été inséré à trois niveaux très spécifiques : après le bloc SPPF (pour un raffinement global des caractéristiques contextuelles), dans la branche P3 (tête haute résolution, dédiée aux *minuscules tumeurs pituitaires*), et dans la branche P5 (basse résolution, dédiée aux *lésions volumineuses*). Cette configuration multi-échelle est en cohérence directe avec la grande variance de taille des tumeurs.
- Sur **YOLOv11s**, nous avons adopté une approche plus massive en créant un bloc hybride **C3K2_CBAM**, remplaçant l'extraction de base du *backbone* aux niveaux P2, P3, P4 et P5. Ce bloc a également été inséré quatre fois supplémentaires dans le *head* après les concaténations FPN/PAN.




Fig. 2: Architecture du module CBAM permettant une extraction des caractéristiques multi-échelles.

B. Axe 2 : Haute Résolution et Profondeur (YOLOv11-HR-D)

Pour traiter spécifiquement les micro-lésions, le sous-échantillonnage de l'architecture standard entraîne une perte d'informations spatiales critique. Nous avons développé l'architecture expérimentale **YOLOv11-HR-D** (*High Resolution Detection*) basée sur la version *nano* qui modifie le réseau sur deux fronts majeurs :

- 1) **Branche P2 (Haute Résolution)** : Ajout d'une 4^{ème} tête de détection fonctionnant sur un *stride* de 4. Concrètement, pour une image 640×640 , la tête opère sur une grille fine de 160×160 pixels (contre 80×80 pour P3), préservant les détails morphologiques fins. Le *neck* a été modifié avec des *Upsample* et des concaténations supplémentaires pour fusionner les caractéristiques profondes avec cette branche.
- 2) **Complexification C3k2** : Par défaut dans YOLOv11n, le paramètre *shortcut* des blocs profonds est sur *False* pour privilégier la vitesse. Nous l'avons passé à *True* (niveaux P4 et P5) pour ajouter des connexions résiduelles internes. Cette capacité d'abstraction accrue vise à mieux différencier les tissus sains des tumeurs aux frontières floues.

V. RÉSULTATS ET DISCUSSION

L'ensemble des métriques globales sur le jeu de test est regroupé dans le Tableau I. Une analyse détaillée par classe est fournie dans le Tableau II.

A. Analyse des mécanismes d'attention

Le module **PSA** sur YOLOv11n améliore toutes les métriques simultanément (Tableau I). Le Tableau II montre que la classe *Gliome* bénéficie de la plus forte hausse (+0,9 % en mAP@50). L'ajout conjoint de C2PSA et de la tête P2 sur YOLOv11s confirme cette dynamique d'excellence, révélant une performance quasi-optimale pour les Méningiomes (0,987) et les images Sans Tumeur (0,994). Ce score exceptionnel sur la classe *No Tumor* valide la capacité de l'architecture attentive à rejeter efficacement le bruit de fond anatomique.

La matrice de confusion (Figure 3) confirme toutefois que le défi persistant demeure la classe *Gliome*. Le modèle a prédit 78 fois un Gliome à tort sur du tissu sain, et a manqué 43 Gliomes (prédits comme fond). Ces erreurs ciblées expliquent la variance de performance sur cette classe et soulignent la complexité de régression des boîtes sur ces tumeurs aux contours infiltrants.



Fig. 3: Matrice de confusion du modèle YOLOv11n-PSA.

L'impact du **CBAM** diffère fortement selon son intégration. Sur YOLOv8n, il améliore la sensibilité (+1,0 point de Rappel) au détriment de la précision spatiale. En revanche, son intégration profonde et massive dans YOLOv11s (remplacement par le bloc hybride C3K2_CBAM) fait chuter le rappel de 1,4 point (0.905 à 0.891), indiquant une augmentation indésirable des faux négatifs (Figure 4). Dans le contexte médical, où manquer une tumeur est dramatique, cette baisse de sensibilité suggère que sature le réseau de modules d'attention peut perturber l'extraction des caractéristiques, le modèle de base offrant déjà une capacité de représentation très robuste.

B. Analyse de la Haute Résolution : Triage vs Chirurgie


Le résultat le plus instructif de l'architecture **YOLOv11-HR-D** réside dans la divergence observée entre les différentes métriques mAP. D'un côté, le HR-D subit une légère baisse sur le rappel et le mAP@50. De l'autre, il est le seul modèle qui parvient à améliorer le mAP@50-95 (passant de 0.739 à

TABLE I: Comparaison globale des métriques de détection.


Famille	Modèle / Modification	Précision	Rappel	F1-Score	mAP@50	mAP@50-95
YOLOv8n	Baseline YOLOv8n (640 × 640)	0.942	0.895	0.918	0.947	0.774
	YOLOv8n + CBAM	0.941	0.906	0.923	0.943	0.735
YOLOv11n	Baseline YOLOv11n (512 × 512)	0.960	0.908	0.934	0.953	-
	YOLOv11n + PSA (512 × 512)	0.964	0.909	0.936	0.958	-
	Baseline YOLOv11n (640 × 640)	0.920	0.892	0.906	0.946	0.739
	YOLOv11-HR-D (P2 + C3k2)	0.898	0.888	0.893	0.940	0.741
YOLOv11s	Baseline YOLOv11s (640 × 640)	0.923	0.905	0.914	0.950	0.774
	YOLOv11s + C3K2_CBAM	0.921	0.891	0.906	0.948	0.745
	YOLOv11s + P2 Head + C2PSA	0.945	0.912	0.928	0.957	0.752

TABLE II: Comparaison de l’Average Precision (mAP@50) par classe pathologique.

Famille	Modèle / Modification	Gliome	Méningiome	Sans Tumeur	Pituitaire
YOLOv8n	Baseline YOLOv8n	0.683	0.854	0.876	0.685
	YOLOv8n + CBAM	0.642	0.808	0.830	0.659
YOLOv11n	Baseline YOLOv11n (512 × 512)	0.906	0.970	0.995	0.941
	YOLOv11n + PSA (512 × 512)	0.915	0.979	0.995	0.944
YOLOv11s	Baseline YOLOv11s (640 × 640)	0.869	0.983	0.990	0.941
	YOLOv11-HR-D (P2 + C3k2)	0.864	0.975	0.989	0.931
	YOLOv11s + P2 Head + C2PSA	0.897	0.987	0.994	0.950



(a) Modèle de base (YOLOv11s)



(b) Modèle adapté (C3k2_CBAM)

Fig. 4: Matrices de confusion comparatives (Baseline vs CBAM massif).

0.741, soit +0,002 point). Cette métrique stricte exigeant un fort taux de chevauchement (IoU) avec la vérité terrain signifie que lorsque YOLOv11-HR-D détecte une tumeur, ses boîtes englobantes sont tracées avec une bien meilleure précision géométrique que la *baseline*.

En imagerie médicale, ce compromis soulève une analyse clinique décisive :

- Si l’objectif clinique est d’obtenir un simple outil de "**triage**" (déterminer le plus vite possible la présence ou non d’une tumeur), la *baseline* ou l’utilisation du module PSA simple reste préférable en raison de leur meilleur

rappel (sensibilité).

- En revanche, si l’outil d’IA doit assister un **chirurgien ou un radiothérapeute** dans la délimitation stricte du volume tumoral à irradier, l’amélioration géométrique apportée par la tête haute résolution (P2) constitue une avancée technique pertinente, justifiant la légère perte de sensibilité globale.

C. Limites méthodologiques et convergence

L’architecture HR-D souffre de l’absence d’une analyse d’ablation isolée : la tête P2 et la complexification C3k2 ayant été ajoutées simultanément, il est impossible de déterminer

laquelle de ces deux modifications est le véritable moteur de la hausse du mAP@50-95.

Par ailleurs, contrairement à nos attentes théoriques, l'ajout de la tête P2 n'a pas amélioré le score sur la classe des tumeurs pituitaires (les plus petites lésions, chutant à 0.931). Cela met en lumière un problème fondamental de **convergence** : l'intégration d'une toute nouvelle tête de détection P2 introduit des dizaines de milliers de nouveaux paramètres non pré-entraînés. La limite imposée de 50 époques est insuffisante pour permettre au réseau d'équilibrer la fonction de perte entre quatre têtes de détection.

Nos tests ont d'ailleurs montré que forcer le modèle à tracer des boîtes trop strictes via un *fine-tuning* avec une pénalité géométrique (*box loss*) accrue à 8.0 conduit à une dégradation sémantique globale (mAP chutant à 0.952, Figure 5). Pour des structures organiques aux limites imprécises comme les gliomes, une contrainte géométrique trop rigide pénalise finalement la capacité du réseau à comprendre la texture tumorale.

Pour les travaux futurs, un allongement significatif du temps d'entraînement (par exemple, 150 époques couplées à une technique d'*early-stopping*) sera crucial pour permettre à ces architectures complexes de converger et d'exploiter pleinement le potentiel des têtes haute résolution.




Fig. 5: Comparaison des métriques avant et après *fine-tuning* avec pénalité de boîte stricte (YOLOv11s + P2 Head + C2PSA).

VI. USAGE DE L'IA GÉNÉRATIVE

Des outils d'intelligence artificielle générative (LLM) — principalement ChatGPT (GPT-4o) et Claude (Sonnet 3.5) — ont été utilisés exclusivement comme support au développement de ce projet et à la rédaction de cet article. Leur utilisation est restée strictement assistée et supervisée : toutes les décisions architecturales, méthodologiques et les interprétations cliniques ont été entièrement définies par les auteurs.

A. Aide au développement du code

L'IA a été sollicitée pour accélérer les tâches techniques fastidieuses. Les fonctions et modules les plus fréquemment générés ou corrigés avec assistance sont : `forward()` du module PSA, `ChannelAttention`, `SpatialAttention`, le bloc hybride `C3K2_CBAM`, ainsi que la structuration du fichier de configuration `yolo11-hr-d.yaml` (définition des couches `Upsample`, `Concat` et de la tête `Detect P2`).

Exemples de prompts utilisés :

- « Voici mon module PSA en PyTorch. La fonction `forward` lève une erreur de dimension lors du `split`. Corrige-la et explique pourquoi. »
- « Génère un bloc CBAM compatible avec l'API Ultralytics (méthode `forward`, attributs `cv1/cv2`) à insérer après le SPPF de YOLOv8n. »
- « Dans ce fichier YAML YOLOv11, ajoute une quatrième tête de détection P2 avec `stride 4`, en modifiant le `neck` pour inclure un `Upsample` et une `Concat` vers P3. »

B. Aide à la rédaction et à la structuration

L'IA a été utilisée pour la reformulation académique et l'amélioration de la fluidité lexicale en français, ainsi que pour l'assistance à la syntaxe $\text{\LaTeX}$ (alignement des colonnes de tableaux, figures TikZ).

Les sections ayant fait l'objet d'un lissage grammatical et stylistique sont : l'Abstract, l'Introduction (Sec. I), la description des modules d'attention (Sec. IV-A), et les légendes des figures. Les sections Résultats (Sec. V) et Conclusion (Sec. VII) ont été rédigées directement par les auteurs sans lissage, afin de préserver l'authenticité de l'interprétation clinique.

Exemples de prompts utilisés :

- « Reformule ce paragraphe en français académique sans en changer le sens. Ne modifie pas les termes techniques entre backticks. »
- « Corrige la syntaxe LaTeX de ce tableau à 6 colonnes pour que les colonnes Précision, Rappel, F1 soient centrées et la colonne Modèle alignée à gauche. »

VII. CONCLUSION GÉNÉRALE

Nos travaux démontrent que l'attention légère PSA est l'optimisation la plus stable pour l'analyse d'IRM cérébrales, améliorant la détection de textures diffuses sans alourdir le modèle. Les modifications structurelles plus profondes (HR-D, CBAM massif) imposent quant à elles des compromis cliniques, forçant à choisir entre la sensibilité de triage (Rappel) et la précision chirurgicale de délimitation (mAP@50-95). Une augmentation du temps d'entraînement sera une étape incontournable pour permettre aux architectures haute-résolution de converger pleinement face à l'hétérogénéité des micro-lésions.

REFERENCES

- [1] G. Litjens *et al.*, "A survey on deep learning in medical image analysis," *Med. Image Anal.*, vol. 42, pp. 60–88, 2017.
- [2] S. Ren *et al.*, "Faster R-CNN: Towards real-time object detection with region proposal networks," *IEEE Trans. Pattern Anal.*, vol. 39, no. 6, pp. 1137–1149, 2015.
- [3] J. Redmon and A. Farhadi, "YOLOv3: An incremental improvement," *arXiv:1804.02767*, 2018.
- [4] G. Jocher, A. Chaurasia, and J. Qiu, "Ultralytics YOLOv8," <https://github.com/ultralytics/ultralytics>, 2023.
- [5] Ultralytics, "Code source et fichiers de configuration YOLO," <https://github.com/ultralytics/ultralytics>, 2024.
- [6] J. Hu, L. Shen, and G. Sun, "Squeeze-and-excitation networks," in *Proc. CVPR*, 2018, pp. 7132–7141.
- [7] S. Woo, J. Park, J.-Y. Lee, and I. S. Kweon, "CBAM: Convolutional block attention module," in *Proc. ECCV*, 2018, pp. 3–19.

- [8] D. Misra *et al.*, “Rotate to attend: Convolutional triplet attention module,” in *Proc. WACV*, 2021, pp. 3139–3148.
- [9] O. Oktay *et al.*, “Attention U-Net: Learning where to look for the pancreas,” in *Proc. MIDL*, 2018.
- [10] M. Msoud Nickparvar, “Brain tumor MRI dataset,” Kaggle, 2021.
- [11] Brain-Tumor-Detection-Wsera, “Tumor detection dataset (v8),” <https://universe.roboflow.com/brain-tumor-detection-wsera/tumor-detection-ko5jp/dataset/8>, 2024, licence CC BY 4.0.